



Scuola di Scienze

Matematiche, Fisiche e Naturali
Corso di Laurea in Informatica
Tesi di Laurea

Individuazione di immagine
alterate da una telecamera RGB

mal funzionante attraverso un
agente addestrato

Detection of failed images from
an RGB camera through trained
agents

Pietro Bernabei
Anno Accademico 2019/20

Contents

1	Introduzione	4
1.1	Motivazioni	4
1.2	Obiettivo	4
1.3	Organizzazione del lavoro	5
2	Fondamenti teorici	6
2.1	Sistemi critici	6
2.1.1	Dependability	6
2.1.2	Le Minacce: guasti, errori e fallimenti	7
2.1.3	Gli attributi della dependability	10
2.1.4	I mezzi per ottenere la dependability	11
2.2	Artificial Intelligence	13
2.2.1	Agente razionale,Misura di prestazione,Ambiente	13
2.2.2	Agenti che apprendono	14
2.2.3	Neural Network	16
2.3	Autonomous Driving	18
2.3.1	Livelli di automazione della guida	18
2.3.2	Visione artificiale	20
2.3.3	Reti neurali applicate all'autonomus driving . .	22
2.3.4	Classificatori	24
2.3.5	Object Recognition	24
2.4	Autonomus driver simulator	25
2.4.1	CARLA	26
2.4.2	Sensori	26
3	Costruzione del dataset	27
3.1	Definizione delle classi	27
3.2	Acquisizione	28
3.3	Sporcatura	29
3.4	Suddivisione del dataset	29

4 Costruzione del detector	31
4.1 Convolutional Neural Network	31
4.1.1 L'architettura	32
4.1.2 Convolutional layer	32
4.1.3 Funzione di attivazione Relu	33
4.1.4 Pooling layer	34
4.1.5 Dense layer	34
4.1.6 Struttura della rete sviluppata	35
5 Esecuzione e risultati	37
5.1 Addestramento del rete convuluzionale	37
5.2 Testing della rete	37
6 Conclusioni e lavori futuri	39
7 A Manuale utente	39

1 Introduzione

1.1 Motivazioni

Nel giro di un paio di secoli il mondo, si è passati dal viaggiare in groppa a un cavallo, alla groppa di una macchina, dal essere il conducente, al condotto. Le macchine a guida autonoma parziali e totali stanno diventando ogni giorno che avanza, realtà. Questa rivoluzione sta permeando il nostro stile di vita, diventando sempre di più accessibili. Questa presenza sempre più forte nella quotidianità di tutti i giorni, fa sì che queste tecnologia debba rispettare degli standard sempre più stringenti, garantendo la continuità del servizio, l'assenza di possibili errori e malfunzionamento. Come per un essere umano, che soffre di miopia, guidare senza occhiali è pericoloso, anche per il sistema di guida autonoma, guidare con le telecamere affette da guasti porta a incidenti. Come verrà espresso in seguito, le telecamere negli attuali sistemi, ricoprono un ruolo decisivo nel momento decisionale della guida autonoma, e un loro malfunzionamento nel processo di acquisizione ripercuote nel sistema decisionale, errori non molto graditi al guidatore.

1.2 Obiettivo

Nella seguente tesi si propone un detector, ovvero un sistema software in grado di rilevare, nel flusso di immagini generate dalla telecamera di un mezzo a guida autonoma, la presenza di guasti nel sistema di acquisizione, come congelamento, pixel bruciati, e tanti altri, per poi notificare i possibili esiti al sistema decisionale del mezzo, prevenendo lo sviluppo di fallimenti.

1.3 Organizzazione del lavoro

Come verrà esposto in seguito un veicolo a guida autonoma, presenta una suite di sensori, attraverso i quali "vede" l'ambiente circostante. Su queste percezioni, il suo sistema decisionale guida il veicolo in sicurezza. Un particolare componente di questa suite di sensori, sono le fotocamere RGB le quali risultano le più impiegate e importanti tra le tutte, e proprio la loro importanza fa sì che un loro guasto, comporti un fallimento nel sistema decisionale. Per questo il detector è posto tra il sistema di acquisizione della fotocamera RGB e il sistema decisionale, al fine di rilevare la presenza dei guasti nel sensore e comunicare questa al sistema di guida su cui prenderà le sue decisioni. Il detector descritto nella seguente tesi impiega una particolare forma di intelligenza artificiale, rete neurale convoluzionale. Come verrà esposto meglio in seguito, una convolutional neural network è una particolare forma di supervised learning, particolarmente efficiente in ambienti grafici, soprattutto per la classificazione di immagini o identificazione di elementi al loro interno. Gli agenti supervisionati, e quindi anche le CNN richiedono una fase di training, nella quale viene definita la loro conoscenza di base (Knowledge base), su cui prenderanno le loro decisioni. Detto ciò lo sviluppo del detector si divide in:

- Definizione e generazione del dataset
- Creazione del modello della ConvNet
- Training del modello
- Testing del modello

2 Fondamenti teorici

2.1 Sistemi critici

Ogni giorno, una persona usa infrastrutture, mezzi, telecomunicazioni, e servizi di qualsiasi genere, affidandosi totalmente al loro funzionamento, alla loro continuità, dando per scontato che non possano subire guasti o malfunzionamenti, perché ove questi avvengano il risultato sarebbe devastante per tutto il nostro sistema di vita. Queste componenti si definiscono come **sistemi critici**, e il loro corretto funzionamento, dipende dalla nostra capacità di analizzarne aspetti quantitativi relativi sia a caratteristiche prestazionali, quali velocità di elaborazione o altre misure di efficienza, sia caratteristiche di sicurezza, disponibilità o affidabilità che dimostrino e ci convincano della adeguatezza dei nostri manufatti per i compiti sempre più critici e delicati per i quali li utilizziamo.

2.1.1 Dependability

La **dependability** è una delle proprietà fondamentali dei sistemi informatici insieme a funzionalità, usabilità, performance e costo. Per fornirne una prima definizione, è necessario illustrare i concetti di: [2].

- **Servizio:** Il servizio fornito da un sistema è il comportamento del sistema stesso, così come viene percepito dai suoi utenti.
- **Utente:** Un utente di un sistema è un altro sistema che interagisce attraverso l'interfaccia del servizio.
- **Funzione di sistema:** La funzione di un sistema rappresenta che cosa ci attendiamo dal sistema; la descrizione della funzione di un sistema è fornita attraverso la sua specifica funzionale. Il servizio è detto corretto se realizza la funzione del sistema.

Quindi **dependability** è la capacità di un sistema di fornire un servizio su cui è possibile fare affidamento in modo giustificato.[3] La dependability presenta tre diversi concetti di cui è necessario tenere conto: [3]

- **Le minacce o impedimenti alla dependability.** Gli impedimenti sono le cause potenziali di comportamenti non previsti.
- **Gli attributi della dependability.** Gli attributi ci permettono di esprimere e verificare il livello di dependability richiesto od ottenuto.
- **I mezzi per ottenere la dependability.** I mezzi sono le tecniche che permettono di ottenere comportamenti corretti, nonostante il verificarsi degli impedimenti.

2.1.2 Le Minacce: guasti, errori e fallimenti

Si definisce come:[3]

- **guasto:** la causa accertata o ipotizzata di un errore, derivante da malfunzionamenti di componenti, interferenze ambientali di natura fisica, sbagli dell'operatore o da una progettazione fallace.
- **errore:** è la parte dello stato del sistema che può causare un susseguente fallimento; in alternativa si definisce errore la manifestazione di un guasto all'interno di un programma o di una struttura dati.
- **fallimento:** di sistema è un evento che occorre quando un errore raggiunge l'interfaccia di servizio, alterando il servizio stesso. Quando un sistema viola la sua specifica di servizio si dice che è avvenuto un fallimento; il fallimento è quindi una transizione da un servizio corretto a un servizio non corretto. La transizione

inversa, da un servizio non corretto ad uno corretto, è detta ripristino.

Il guasto può rimanere dormiente per un certo periodo, fino alla sua attivazione. L'attivazione di un guasto porta ad un errore, che è la parte dello stato del sistema che può causare un successivo fallimento. I guasti di un sistema possono essere classificati secondo diversi punti di vista, ad esempio fisico, logico e di interazione. Un'altra suddivisione può essere fatta in base alla natura del guasto: un guasto può essere intenzionale o accidentale, malizioso oppure non malizioso; ed ancora in base alla persistenza dove abbiamo guasti permanenti, transienti ed intermittenti. Per una tassonomia completa si rimanda a [2]

Il fallimento di un componente si verifica quando il servizio fornito devia dalla sua specifica: si verifica nel momento in cui un errore del componente si manifesta alla sua interfaccia, e diventa quindi un guasto per il sistema. Il fallimento è quindi l'effetto, osservabile esternamente, di un errore nel sistema; gli errori sono in stato latente fino a che non vengono rilevati e/o non producono un fallimento.

La deviazione dal servizio corretto può assumere diverse forme, che vengono chiamate modi di fallimento e sono classificati secondo la loro gravità (severity).

Chain Fault-Error-Failure Un sistema è formato da un insieme di componenti che interagiscono tra loro, perciò lo stato del sistema è l'insieme degli stati dei suoi componenti. Un guasto causa inizialmente un errore nello stato di uno (o più) componenti, ma il fallimento del sistema non si verifica fino a quanto l'errore non raggiunge l'interfaccia del servizio. La propagazione di errori può permettere ad un errore di raggiungere l'interfaccia di servizio. Questo insieme di meccanismi costituisce la catena di impedimenti **guasto-**

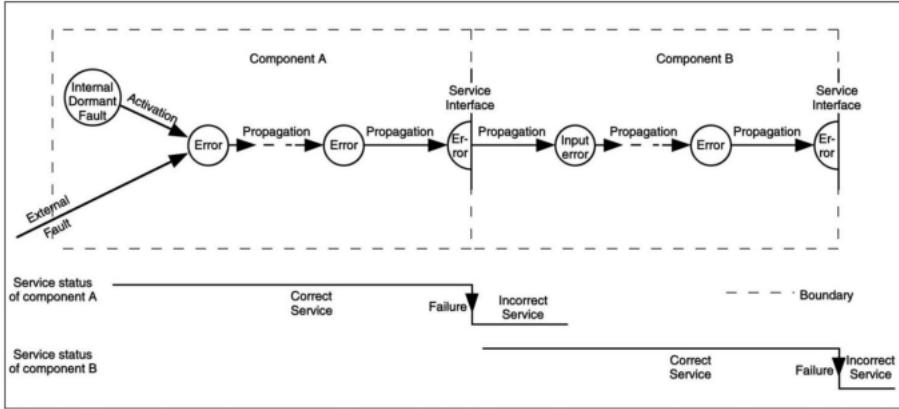


Figure 1: Catena di guasto errore fallimento (figura ripresa da [2])

errore-fallimento (fault-error-failure) La propagazione all'interno di un componente (propagazione interna) è causata dal processo di elaborazione: un errore viene successivamente trasformato in altri errori. La propagazione da un componente A verso un componente B che riceve un servizio da A (propagazione esterna) (Fig:1) avviene quando un errore raggiunge l'interfaccia di servizio del componente A. A questo punto, il servizio che B riceve da A diventa non corretto e il fallimento di A appare a B come un guasto esterno, e si propaga come un errore all'interno di B (Fig:1). Per esempio, nel caso di un veicolo a guida autonoma, un guasto nella lente o nel sensore della fotocamera, genera un errore. Quando raggiunge l'interfaccia di servizio genera un fallimento per la fotocamera. Per il sistema di visione artificiale, il fallimento della fotocamera risulta come un guasto, siccome non eroga il servizio correttamente. Questo genera un errore interno al sistema, che come viene dimostrato nella seguente tesi [11], porta a un fallimento sistema decisionale della macchina a guida autonoma. Il detector proposto si pone tra la fotocamera e il sistema decisionale per intercettare il fallimento della fotocamera impedendo così il fallimento del sistema decisionale che avrebbe conseguenze catastrofiche sui passeggeri e su

tutto ciò che li circonda.

2.1.3 Gli attributi della dependability

Il concetto di dependability è la sintesi di più attributi che forniscono misure quantitative o qualitative del sistema:

- **Affidabilità (reliability):** è la capacità del sistema di erogare un servizio corretto in modo continuo; misura la fornitura continua di un servizio corretto.
- **Manutenibilità (maintainability):** è la capacità del sistema di subire modifiche e riparazioni; misura il tempo necessario per ristabilire un servizio corretto.
- **Disponibilità (availability):** è la prontezza del sistema nell'erogare un servizio corretto; misura la fornitura di servizio corretto, rispetto all'alternanza fra servizio corretto e non corretto.
- **Confidenzialità (confidentiality):** è l'assenza di diffusione non autorizzata di informazioni; misura l'assenza di esposizione non autorizzata di informazione.
- **Integrità (integrity):** descrive l'assenza di alterazioni improprie del sistema; misura l'assenza di alterazioni improprie dello stato del sistema.
- **La sicurezza (safety)** è l'assenza di conseguenze catastrofiche sugli utenti e sull'ambiente circostante. .
- **sicurezza (security)** è vista come la contemporanea esistenza di availability solo per gli utenti autorizzati, confidentiality, e integrity, dove per “improprie” si intende “non autorizzate” [9].

Nella loro definizione, la disponibilità e la affidabilità evidenziano la capacità di evitare i fallimenti, mentre la safety e la security evidenziano la capacità di evitare specifiche classi di fallimenti come ad esempio fallimenti catastrofici e accesso non autorizzato alle informazioni. Se i modi di fallimento previsti sono specificati e limitati, si parla di sistemi **fail-controlled**; un sistema i cui fallimenti sono limitati soltanto all'interruzione del servizio sono chiamati **fail-stop** o **fail-silent**. I sistemi **fail-safe**, invece, sono quelli per cui i fallimenti possibili sono solamente fallimenti non catastrofici.

2.1.4 I mezzi per ottenere la dependability

Lo sviluppo di sistemi dependable richiede l'utilizzo combinato di quattro tipologie di tecniche:

- **prevenzione dei guasti**, per prevenire l'occorrenza o introduzione di guasti nel sistema;
- **tolleranza ai guasti**, per erogare un servizio corretto anche in presenza di guasti;
- **rimozione dei guasti**, per ridurre il numero o la gravità dei guasti;
- **previsione dei guasti**, per stimare il numero di guasti presenti nel sistema, la loro incidenza futura, o le loro probabili conseguenze.

Prevenzione dei guasti: La “Fault Prevention” viene effettuata ricorrendo a tecniche e processi di controllo di qualità sia durante la progettazione del software che durante la produzione dei componenti hardware.

Tolleranza ai guasti: La “Fault Tolerance” mira a preservare l’erogazione di un servizio corretto in presenza di guasti attivi. Essa viene solitamente implementata tramite rilevazione di errori (error detection) e conseguente recupero dello stato del sistema (system recovery). In particolare, la rilevazione degli errori origina un segnale di errore all’interno del sistema; esistono due classi di tecniche di rilevazione di errori: **concurrent error detection** viene effettuata durante l’erogazione del servizio, **preemptive error detection** viene effettuata quando l’erogazione del servizio è sospesa e controlla la presenza di errori latenti e guasti dormienti. Il recupero dello stato del sistema trasforma uno stato che contiene uno o più errori attivi (ed eventualmente guasti), in uno stato che non contiene errori rilevati e guasti che possono essere nuovamente attivati. Il recovery consiste in **error handling** e **fault handling**. **Error handling** elimina gli errori dallo stato del sistema mentre **Fault handling** impedisce che i guasti che sono stati localizzati vengano nuovamente attivati.

Rimozione dei guasti: La **Fault Removal** viene effettuata sia durante la fase di sviluppo, che durante la vita operazionale del sistema. La rimozione dei guasti è uno degli obiettivi del processo di verifica e validazione (V&V). La verifica è un processo attraverso cui si determina se il sistema soddisfa alcune proprietà determinate dalle specifiche o imposte all’inizio della fase di sviluppo; se così non è si cerca di individuare il guasto che impedisce di soddisfare tali proprietà e lo si corregge. La validazione consiste invece nel controllare se il sistema soddisfa le proprie specifiche e se le specifiche descrivono adeguatamente la funzione intesa per il sistema. La rimozione dei guasti durante la sua vita operazionale è manutenzione correttiva o preventiva. La manutenzione correttiva ha l’obiettivo di rimuovere guasti che sono stati segnalati come la causa di uno o più errori, la manutenzione preventiva cerca di scovare e rimuovere i guasti prima

che causino degli errori durante la normale operazione del sistema.

Previsione dei guasti: La **Fault Forecasting** è condotta effettuando una valutazione del comportamento del sistema rispetto all'occorrenza e attivazione dei guasti. La valutazione può essere di due tipi: qualitativa, che mira ad identificare, classificare e valutare i modi di fallimento o le combinazioni di eventi che porterebbero ad un fallimento del sistema; quantitativa (o probabilistica), che mira a valutare in termini probabilistici il grado con cui alcuni attributi vengono soddisfatti dal sistema; questi attributi sono in questo caso visti come misure.

2.2 Artificial Intelligence

Nel pensiero comune quando si pensa all'intelligenza artificiale, si immagina un entità in grado di pensare, in grado di sostituirci. Nella realtà, l'intelligenza artificiale è quella branca dell'Informatica che dato un determinato problema, definisce agenti in grado di trovare in modo efficace le migliori soluzioni. Quindi il campo di applicazione dell'intelligenza artificiale non è unico ma è suddiviso in sottodiscipline, dove si va da aree più generali come l'apprendimento e la percezione, ad altre più specializzate come il gioco degli scacchi e la dimostrazioni di teoremi matematici, ad altre anche più complesse e complete come la guida autonoma.

2.2.1 Agente razionale,Misura di prestazione,Ambiente

Nello specifico l'intelligenza artificiale si occupa di progettare **agenti razionali**, che posti in un **ambiente**, riescano a massimizzare la propria **misura di prestazione**.^[10] Un **agente** è definito come un sistema che percepisce il suo ambiente attraverso dei sensori e agisce su di esso mediante attuatori. Per farsi un idea, si può assumere che l'essere

umano sia un agente, che fornito di sensori, come occhi, orecchie e altri organi, sente l'ambiente circostante, e attraverso altrettanti organi (attuatori), come mani, gambe e bocca, interagisce con l'ambiente o altri agenti. Un agente fisico, come una macchina a guida autonoma, ha sensori come: telecamere, sensori a infrarossi, e radar, attraverso cui vedere, mentre per agire: motore, freni, e tanti altri. Un'altra cosa che accomuna tutti gli agenti, sono le **percezioni**, termine usato per indicare gli input percettivi dell'agente in dato istante.[10] La totalità delle percezioni generate dall'agente in tutta la sua storia, è definita invece come **sequenza percettiva**, dove in generale la scelta dell'azione di un agente in un qualsiasi istante può dipendere dall'intera sequenza percettiva osservata fino a quel momento. In termini matematici la rappresentazione del comportamento di un agente, è descritto dalla **funzione agente**, che descrive la corrispondenza tra una qualsiasi sequenza percettiva e una specifica azione. Se la funzione agente è la rappresentazione matematica dell'agente, con il termine **programma agente** si indica la sua implementazione concreta in esecuzione sull'architettura dell'agente. [10]

2.2.2 Agenti che apprendono

Si definisce un agente che apprende se migliora le proprie prestazioni nelle attività future dopo aver effettuato le osservazioni sul mondo. [10] Questo processo è decisivo per un agente per tre motivi:

- il programmatore non può anticipare tutte le possibili situazioni che l'agente si potrà trovare davanti.
- il programmatore non può anticipare tutti i cambiamenti nel tempo.
- il programmatore spesso non sa come programmare loro la soluzione a un problema.

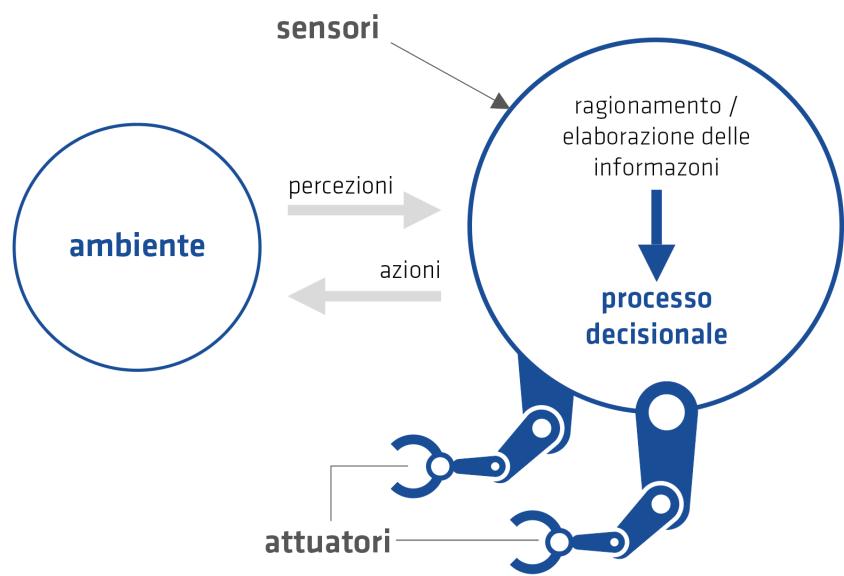


Figure 2: Esempio di agente razionale

[10]

Detto ciò, come esistono agenti diversi per problemi diversi, esistono apprendimenti diversi per ogni agente, che possono essere applicati alle varie componenti che lo compongono. Una loro classificazione si basa su quattro fattori: la componente che viene migliorata, la rappresentazione usata per i dati e i componenti, la conoscenza a priori, e per ultimo i feedback disponibili da apprendere. Su quest'ultimo sono stati sviluppati tre diversi paradigmi di apprendimento:

- **unsupervised learning:** l'agente apprende patterns dall'input senza feedback espliciti.
- **reinforcement learning:** l'agente apprende da una serie di rinforgi, punizioni o premi.
- **supervised learning:** all'agente sono forniti coppie di valori input-output, da cui apprende una funzione che mappi il collegamento tra input e output.

Nello specifico, il compito di un apprendimento supervisionato è quello che dato un training set di N esempi della forma input-output:

$$(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$$

dove ogni valore y è generato da un funzione sconosciuta $y = f(x)$, questa scopre una funzione h che approssima la funzione f . Il learning problem si può definire in due maniere a seconda dell'output y : nel caso in cui y è uno di un insieme finito di valori il problema è definito **classificazione** (binaria o booleana, nel caso di due sole scelte), mentre se y è un numero è definito come **regressione**.

2.2.3 Neural Network

Una particolare forma di supervised learning, come ci suggerisce il titolo del seguite capitolo, sono le artificial neural network o più brevemente

mente neural network. La **rete neurale** è composta da un insieme di nodi o unità, connesse da link orientati.[10] La topologia e le proprietà dei nodi determinano le proprietà della rete.

Neurone Ciascun neurone o nodo, ha un insieme di input e produce un singolo output che può essere inviato a un gruppo di altri neuroni. Questo si attiva quando una combinazione lineare dei suoi input superano la sua threshold. L'output dei neuroni finali sarà il risultato dello scopo della rete.

Funzione di attivazione In generale un neurone, calcola una somma pesata dei suoi input:

$$in_j = \sum_{i=0}^n w_{i,j} a_i$$

A questa è applicata la **funzione di attivazione** g , dalla quale si ottiene l'output:

$$a_j = g(in_j) = g\left(\sum_{i=0}^n w_{i,j} a_i\right)$$

Collegamenti I neuroni sono interconnessi tra di loro, al fine di propagare il risultato della funzione di attivazione di un nodo padre a un nodo figlio. Oltre a propagare il risultato tra neuroni, il collegamento ha anche un peso numerico $w_{i,j}$ associato, il quale determina la forza e il segno della connessione.

feed-forward network Definito il modello matematico di ogni neurone, questi si connettono insieme attraverso i collegamenti, a formare una rete. Esistono due principali tipologie di network: La **feed-**

forward network, che prevede connessioni solo in una direzione, formando un DAG, directed acyclic graph. Ogni nodo riceve gli input dai nodi superiori e invia gli output a nodi inferiori. Non sono previsti cicli. Questa tipologia di rete, rappresenta una funzione del corrente input, senza mantenere al suo interno, nessun tipo di stato se non i pesi dei collegamenti. Il **recurrent network**, prevede che i suoi neuroni usino il proprio output come feedback per il proprio input, così che i livelli di attivazione della rete formano un sistema dinamico che raggiunge uno stato stabile o esibiscono oscillazioni o addirittura comportamenti caotici. Questa caratteristica, permette alla rete di supportare una memoria a breve termine.

2.3 Autonomous Driving

Nell'ultimo decennio, il settore dell'Automotive è stato in continua evoluzione. In particolar modo, le grandi aziende automobilistiche e molti gruppi di ricerca si sono mossi verso l'automazione della guida ed il miglioramento delle infrastrutture già esistenti. I motivi di questo interesse del settore verso la guida autonoma sono vari:

- riduzione del numero di incidenti, anche fino al 90
- riduzione dei consumi,
- riduzione delle emissioni di CO_2 ,
- riduzione di tutte le varie problematiche della sicurezza stradale.

2.3.1 Livelli di automazione della guida

La SAE International, un ente di standardizzazione automobilistica, nel 2014, pubblica un nuovo standard internazionale, il J3016 ("Levels of Driving Automation"). In questo sistema di classificazione,

all'aumentare del livello di automazione, la responsabilità del conducente passa dalla guida alle attività di supervisione. Lo standard suddivide l'automazione in 6 livelli, dal livello 0, in cui è assente qualsiasi tipologia di automazione, al livello 5, dove il sistema guida in maniera completamente autonoma. Per una esposizione più completa si rimanda alla figura 3

- Livelli 0: Veicoli privi di qualsiasi sistema di automazione.
- Livello 1: Veicoli i quali mettono a disposizione dell'autista, almeno un sistema di assistenza, per esempio, l'assistenza alla frenata.
- Livello 2: Veicoli i quali combinano due o più sistemi avanzati di assistenza alla guida, come l'adaptive cruise control, Lane-Keeping assist, e l'Automatic Emergency Braking. Tutti questi rientrano sotto la dicitura ADAS (Advanced Driver-Assistance Systems).
- Livello 3: Veicoli definiti a guida semi-autonoma, siccome sono in grado di gestire situazioni variegate, anche al di fuori di un contesto autostradale. Nel senso che si prendono la responsabilità di gestire tratti del tragitto, richiedendo però alla fine di questi la ripresa del controllo da parte del conducente. Nel caso questo non avvenisse, arresteranno in sicurezza il veicolo.
- Livello 4 Veicoli definiti a guida autonoma, sono dotati di un set di tecnologie in grado di procedere per lunghi tragitti, superando una varietà di ostacoli, come i caselli autostradali. Tuttavia il loro funzionamento sarà limitato:
 - ad una determinata area geografica,
 - condizioni meteo avverse,



SAE J3016™ LEVELS OF DRIVING AUTOMATION

	SAE LEVEL 0	SAE LEVEL 1	SAE LEVEL 2	SAE LEVEL 3	SAE LEVEL 4	SAE LEVEL 5
What does the human in the driver's seat have to do?	You are driving whenever these driver support features are engaged – even if your feet are off the pedals and you are not steering	You must constantly supervise these support features; you must steer, brake or accelerate as needed to maintain safety		You are not driving when these automated driving features are engaged – even if you are seated in "the driver's seat"	When the feature requests, you must drive	These automated driving features will not require you to take over driving
What do these features do?	These are driver support features			These are automated driving features		
Example Features	These features are limited to providing warnings and momentary assistance	These features provide steering OR brake/acceleration support to the driver	These features provide steering AND brake/acceleration support to the driver	These features can drive the vehicle under limited conditions and will not operate unless all required conditions are met	This feature can drive the vehicle under all conditions	
	<ul style="list-style-type: none"> • automatic emergency braking • blind spot warning • lane departure warning 	<ul style="list-style-type: none"> • lane centering OR • adaptive cruise control 	<ul style="list-style-type: none"> • lane centering AND • adaptive cruise control at the same time 	<ul style="list-style-type: none"> • traffic jam chauffeur 	<ul style="list-style-type: none"> • local driverless taxi • pedals/steering wheel may or may not be installed 	<ul style="list-style-type: none"> • same as level 4, but feature can drive everywhere in all conditions

Figure 3: classificazione SAE

- da una velocità massima e così via.
- Livello 5 Veicoli privi di qualsiasi limite e conducente, capaci di procedere in qualsiasi condizione e luogo.

2.3.2 Visione artificiale

Come definito nella sezione precedente dedicata all'intelligenza artificiale, ogni agente prende in input una sensazione, la elabora, prende una decisione, e la attua con gli attuatori. Applicando questo concetto all'autonomus driving, anche questi hanno una serie di sensori, che gli permettono di prendere coscienza dell'ambiente circostante in cui è immersa la vettura. Le principali tecnologie che compongono la visione artificiale avanzata dei veicoli a guida autonoma sono[4]:

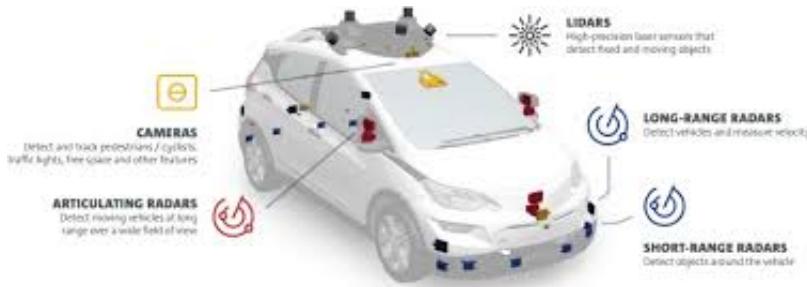


Figure 4: Schema di posizionamento dei sensori su veicolo a guida autonoma

- Fotocamere
- Radar
- Lidar
- GPS

come si può vedere in 4 Tutte insieme, forniscono un modello del ambiente circostante (3D), attraverso immagini bidimensionali(2D). Lo scopo della visione artificiale è proprio quella di riprodurre la vista umana.[13] Le fotocamere fra tutte le tecnologie risultano essere la più presente e sfruttata al momento. Per questo motivo per il lavoro di tesi è stato sviluppato l'agente addestrato con questo scopo

LIDAR - Light Detection And Ranging Il Lidar è solito essere installato sul tettuccio del veicolo, è un sensore che attraverso l'emissione e ricezione di segnali luminosi, laser, ottiene informazioni fisiche dell'ambiente e cinematiche sul veicolo.

RADAR - RADio Detection And Ranging E' un sistema che utilizza onde radio trasmesse nell'ambiente, al fine di raccogliere informazioni sugli ostacoli intorno al veicolo e aumentare la consapevolezza del posizionamento degli altri veicoli presenti. Questo sensore

tiene d'occhio le altre auto e indica al veicolo autonomo di accelerare o rallentare a seconda del comportamento degli altri conducenti [4].

Videocamera Le telecamere sono necessarie nel sistema di trasporto intelligente affinché si riconoscano gli ostacoli rispetto alla posizione e alla velocità del veicolo in considerazione. Le immagini bidimensionali derivanti da una singola fotocamera o le mappe 3D risultanti dall'utilizzo della doppia fotocamera, potrebbero individuare in modo stereoscopico lo spazio disponibile per i movimenti autonomi del veicolo. Queste immagini o mappe vengono utilizzate per estrarre informazioni quantitative dalle scene e per tracciare gli obiettivi del veicolo. Le immagini sono segmentate in un certo numero di pixel. Ogni pixel viene elaborato e memorizzato, il che richiede un'elevata velocità di calcolo ed un elevato spazio di archiviazione [4].

GPS - Global Positioning System Il Sistema di Posizionamento Globale, attraverso una rete dedicata di satelliti artificiali in orbita, fornisce a un terminale mobile o ad un ricevitore GPS informazioni sulle sue coordinate geografiche e sul suo orario in quasi tutte le condizioni atmosferiche ed ovunque non vi siano ostacoli che potrebbero impedirne l'invio e la ricezione dei segnali (edifici molto alti, gallerie, ecc.), generando errori dell'ordine di metri.

2.3.3 Reti neurali applicate all'autonomus driving

Le Reti Neurali sono oggi ampiamente accettate come soluzioni dominanti per la visione artificiale, per il riconoscimento vocale e per l'elaborazione del linguaggio naturale. Nel campo della visione artificiale, le neural network elaborano le informazioni ottenute dai sensori, e ne estraggono informazioni utili al fine di prendere decisioni sul come muoversi, garantendo la sicurezza dei viaggiatori, e degli utenti esterni al veicolo. Questo sistema presenta comunque delle criticità,

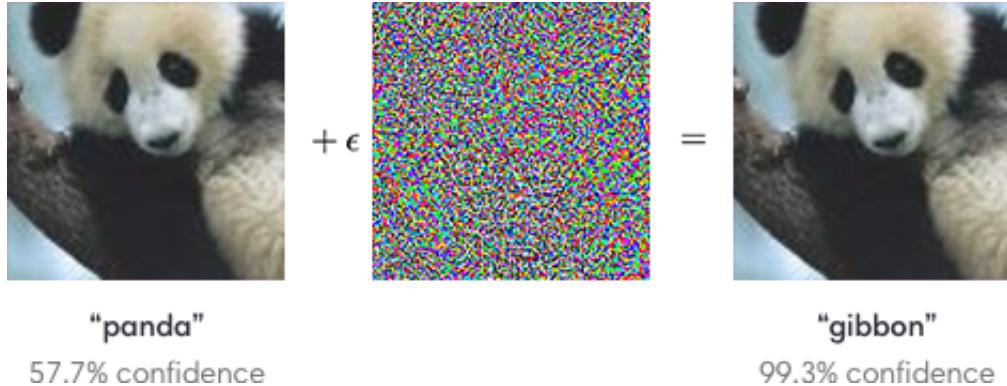


Figure 5: Adversarial Examples

come una non corretta interpretazione dell’ambiente a causa di guasti, che minano la sicurezza dei passeggeri, ma anche tutto ciò che circonda il veicolo. Per quanto riguarda le prestazioni misurate su questa tecnologia, sono stati registrati punteggi di accuratezza spesso corrispondenti a quelli di un individuo umano, su benchmark chiave. Ben diversi, invece, sono stati i punteggi osservati quando si considerano casi peggiori[11]. Con casi peggiori si vuole intendere quei casi definiti Adversarial Examples [5] o input perturbati, anche solo leggermente, che dal punto di vista umano risultano sempre comprensibili, mentre da quello della macchina, cambiano totalmente di significato. Un esempio di questo, è rappresentato dalla figura 5. Questa mostra una rete neurale allenata nel riconoscimento di animali, che all’applicazione di un semplice filtro cambia totalmente risposta alla classificazione, mentre per un occhio umano questa variazione non modifica il significato dell’immagine. Naturalmente, se queste reti vengono utilizzate su veicoli che devono muoversi in un ambiente nel quale si trova un’eterogeneità di soggetti e comportamenti, si parla di contesti nei quali affidabilità, sicurezza e tutti gli altri attributi che definiscono la dependability di un sistema sono al primo posto in ordine di importanza.

2.3.4 Classificatori

Una attività importante delle reti neurali nella guida autonoma, è il processo di classificazione; ovvero l’identificazione di particolari caratteristiche intrinseche di un insieme di immagini o fotogrammi, sulle quali prendere delle decisioni. Come detto in precedenza, le reti neurali presentano delle criticità in presenza di immagini prese in input trasformate spazialmente [5]: con questo termine si intende rappresentare tutte le possibili trasformazioni che un’immagine può subire, ad esempio ruotandola, tagliandola, scalandola ecc. Queste sono trasformazioni naturali e sono utilizzate in vari contesti:

- verificare il livello di completezza di un classificatore,
- allenare una rete neurale,
- ricreare scenari o situazioni con cui il veicolo su cui è installata una determinata rete può avere a che fare.

Con il termine ”trasformata spazialmente” non ci si deve immaginare una modifica profonda del fotogramma in questione, ma anzi, basta anche solo una piccola rotazione, di meno di un grado, per far sì che il classificatore confonda, ad esempio, un revolver con una trappola per topi [5], il che, pensando ad un utilizzo anche diverso da quello che se ne fa su un veicolo a guida autonoma, può far sorgere molte preoccupazioni e domande.

2.3.5 Object Recognition

In generale, ci si riconduce al problema dell’Object Recognition o riconoscimento artificiale degli oggetti. Questo richiede che ci sia una nozione di somiglianza visiva, difficile da far apprendere ad un sistema: significherebbe catturare e insegnare ad una macchina la nozione di percezione umana [5].

Tuttavia, oggi, le DNN (Deep Neural Network) hanno raggiunto prestazioni all'avanguardia, talvolta competitive con la percezione umana. Una delle sfide principali nella guida autonoma è il cambiamento ambientale che un qualsiasi sistema autonomo può incontrare, ovvero: le differenti distanze e angolazioni con cui viene percepito l'ambiente circostante dai sistemi di visione artificiale variano ogni volta che il veicolo si muove nello spazio [6] . Purtroppo, nel contesto della guida autonoma, anche un piccolo errore di valutazione nella navigazione potrebbe causare incidenti altamente devastanti.

2.4 Autonomus driver simulator

Lo sviluppo della guida senza conducente è un argomento attuale e di grande interesse, su cui molte società automobilistiche stanno investendo dato che promette di essere un mercato da miliardi di dollari. Di contro, la guida in ambiente cittadino è una sfida molto più grande, per via del maggiore grado di variabilità degli scenari che si possono presentare e degli oggetti che devono essere riconosciuti, ed è necessario ancora molto lavoro prima che sia disponibile un sistema in grado di muoversi da solo in questi ambienti senza pericolo e in modo efficiente. Nell'ottica dello sviluppo di un sistema di guida autonoma efficiente e sicuro, si rende necessario lo sviluppo di metodi e strumenti per il miglioramento dell'efficienza del prodotto e per la validazione dello stesso. Tra le tecniche utilizzate per automobili a guida autonoma ci sono metodi di apprendimento automatico che richiedono una gran quantità di immagini, inoltre sia per lo sviluppo che soprattutto per la validazione, si deve considerare che esistono una quantità infinita di scenari (situazioni) che si possono presentare e che il sistema progettato deve essere in grado di agire nel modo più sicuro in ognuno di essi. Il problema è di per sé mal posto, visto che non è dato sapere se un'auto che reagisce correttamente in una certa situazione farà lo stesso cambiando qualche variabile dello scenario. Lo sviluppo e la validazione

delle auto a guida autonoma si configura per quanto detto come molto complicato e costoso, visto che è necessario effettuare un gran numero di prove in diversi scenari. Per aiutare a risolvere il problema dei costi dello sviluppo con testing in ambiente fisico e della richiesta di dati che abbiamo presentato, sono stati sviluppati dei simulatori che permettono di sperimentare il software sviluppato in un ambiente virtuale, tra questi NVIDIA DRIVE Constellation, AirSim, e CARLA Simulator. Questi simulatori riproducono scenari di guida cittadina in cui è possibile testare un auto a guida autonoma che raccoglie dati dall'ambiente. Per le considerazioni fatte in precedenza, un simulatore si presenta come un alleato fondamentale nel processo di sviluppo e di validazione. Infatti l'alta avidità di dati da parte degli algoritmi di machine learning impiegate dal sistema di guida autonoma, viene soddisfatto dalla capacità del sistema simulatore, di generare centinaia di migliaia di riproduzioni, nello specifico quello fisicamente e eticamente più difficili da riprodurre nello sviluppo su strada.

2.4.1 CARLA

Tra quelli citati in precedenza, il simulatore impiegato per il progetto, è CARLA. Un simulatore grafico open source costituito da un'architettura client-server scalabile, dove il server è responsabile di tutto ciò che riguarda la simulazione dell'ambiente in tutti i suoi aspetti: rendering del sensore, calcolo della fisica, aggiornamenti sullo stato del mondo e sui suoi attori e molto altro. Mentre il lato client consiste in una somma di moduli client che controllano la logica degli attori sulla scena e impostano le condizioni del mondo.

2.4.2 Sensori

Come in un veicolo reale, CARLA predisponde una suite di sensori preimpostasti, fotocamere RGB e pseudo sensori che forniscono ground-

truth depth e ground-truth semantic segmentation . La loro posizione, numero e direzione possono essere specificate dal client. E proprio della fotocamera RGB di CARLA si farà uso al fine di acquisire le immagini per il dataset.

3 Costruzione del dataset

Un agente che impiega il paradigma del supervised learning, richiede un dataset, per formare la propria conoscenza di base del mondo che lo circonda. Nel caso di un classificatore di immagini, la componente principale di questa mole di dati, sono appunto le immagini. A ciascuna sarà applicata un filtro che simuli un particolare guasto per poi essere suddivise in tre dataset diversi, uno per ogni fase del procedimento di training e testing della rete. In maniera più schematica la creazione del dataset si basa sulla seguente procedura:

- Definizione delle classi
- Acquisizione immagini
- Sporcatura immagini
- Suddivisione del dataset

Ciascuno step è illustrato in dettaglio nei paragrafi seguenti.

3.1 Definizione delle classi

Il problema della classificazione delle immagini è un problema che come dice il verbo, deve assegnare a un elemento in input una classe. Quindi le classi, o etichette(label) sono gruppi di elementi che hanno determinate caratteristiche in comune. Nel caso del detector, le classi rispecchiano i diversi guasti che la fotocamera può subire. Per una esposizione

completa dei guasti che sono stati presi in considerazione si rimanda a [11]. Le classi prese in considerazione per la costruzione dei vari dataset su cui sarà allenato l’agente, sono diciotto, di cui una rappresenta le immagini pulite(Golden Run), una per ogni guasto, e l’ultima (All) contiene al suo interno tutte e 16 i guasti presi in considerazione

- | | | |
|---|---|---|
| <ul style="list-style-type: none">• Golden Run• Blur• Black• Brightness• 50 death pixels• 200 death pixels | <ul style="list-style-type: none">• Nodemos• Noise• Sharpness• Brokenlen• Icelens• Banding | <ul style="list-style-type: none">• Greyscale• Condensation• Dirty lens• Chromatic aberration• Rain• All |
|---|---|---|

3.2 Acquisizione

Definite le classi, la fase successiva nella costruzione dei dataset, è l’acquisizione delle immagini. Per questa fase entra in gioco CARLA. Avviato il suo lato server, il lato client è stato impostato per generare 517 simulazioni diverse, ovvero 517 ambienti generati casualmente, con condizioni atmosferiche e punti di generazione del veicolo diverse. In ciascuna delle simulazioni il veicolo si muove nelle vie della città, seguendo percorsi casuali. Durante il tragitto il Client è stato impostato per acquisire 300 immagini dal sensore della fotocamera frontale della vettura, nel formato .png e ciascuna dalle dimensioni di 800*600 pixels. Per fare ciò è stato impiegato lo script del progetto github ”Carla Script”. Si rimanda alla sezione Manuale Utente.

3.3 Sporcatura

Ottenute queste grande mole di immagini pulite, prive di qualsiasi "errore", questa fase del processo, prevede l'applicazione dei guasti alle immagini. Guasti che sono simulati da filtri ripresi dal progetto github di Francesco Secci, "Python Image Failures", i quali sono stati riadattati per l'uso nella seguente tesi.

Per una illustrazione completa dei guasti si rimanda a [11], da cui è stato ripreso lo studio su l'effetto di alcuni guasti alla fotocamera sul sistema decisionale del veicolo a guida autonoma portino a un rate di fallimenti più elevato. Di seguito si riporta una breve rappresentazione della stessa immagine, acquisita dalla fotocamera di un veicolo nel simulatore CARLA, a cui è stata applicata i diversi filtri impiegati nel progetto.

3.4 Suddivisione del dataset

La Convnet sviluppata, è un classificatore binario, e come tale distingue solamente tra due classi, immagini pulite e immagini sporche, ovvero: golden run e malfunzionamento. Detto ciò sono stati costruiti 17 dataset diversi, ciascuno per ogni classe. Ogni dataset è composto da 314400 elementi, di cui $\simeq 75\%$ come training set, $\simeq 20\%$ come validation set, e il restante $\simeq 5\%$ come test set. Ognuno di questi 3, è a sua volta equamente suddiviso nelle due classi che lo compongono.

Questa suddivisione tra training set e validation set delle immagini, risulta molto importante nella fase di training dei modelli, come si vedrà in seguito. Uno schema di suddivisione (o immagine):

- Training set: 240000 elementi
 - Golden Run: 120000 elementi
 - Dirty Run: 120000 elementi

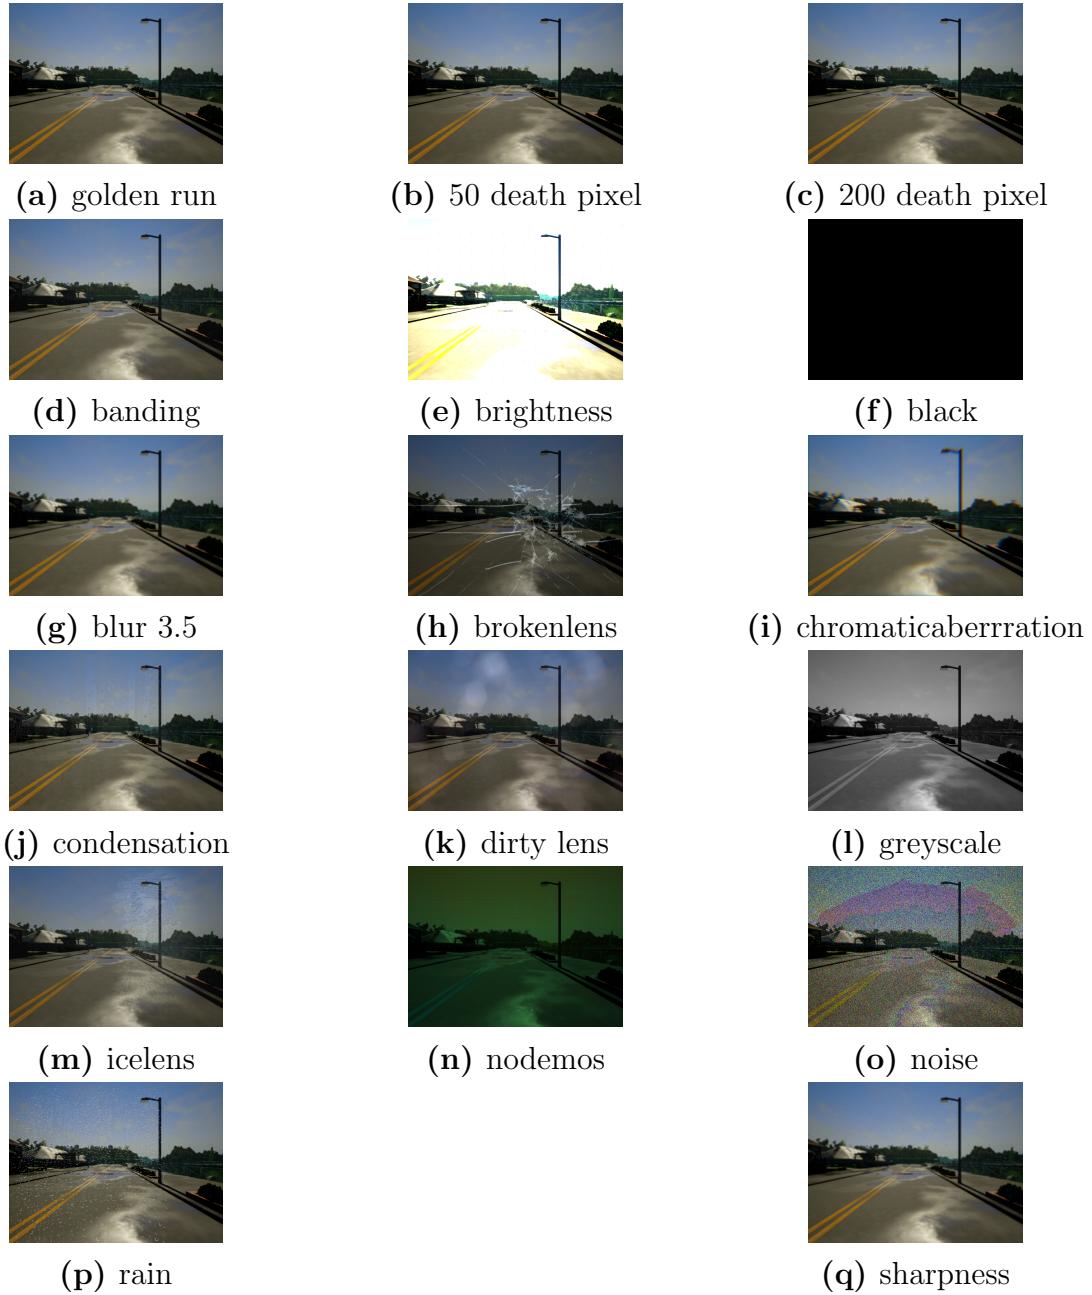


Figure 6: Esempi dei filtri applicati

- Validation set: 60000 elementi
 - Golden Run: 30000 elementi
 - Dirty Run: 30000 elementi
- Test set: 14400 elementi
 - Golden Run: 7200 elementi
 - Dirty Run: 7200 elementi

4 Costruzione del detector

Lo scopo del detector, è quello di individuare all'interno del flusso di immagini della fotocamera, la presenza di distorsioni, ovvero riuscire a prevenire l'insorgere dei fallimenti nel sistema decisionale a causa di un guasto alla fotocamera. Per perseguire il suo scopo, il detector deve essere in grado di classificare ciascuna immagine del flusso, tra immagini pulite, ovvero immagini che non generano fallimenti nel sistema,e immagini sporche, generate da un guasto.Questa distinzione binaria, tra le due sole tipologie di immagini, scaturisce dal fatto che non è richiesta l'identificazione precisa di un singolo guasto,(multiclassificatore), ma si richiede solo la distinzione tra elemento buone e elemento cattive. L'elemento classificatore è svolto da una rete neurale convoluzionale o ConvNet. Come dice il nome, la ConvNet è una tecnologia basata sulle reti neurali più generiche, ed è già ampiamente impiegata nei sistemi di riconoscimento grafico, come classificatori, object detection oltre a vocal recognition.

4.1 Convolutional Neural Network

Una rete neurale convoluzionale è una rete neurale di tipo feed-forward network dove la strato convoluzionale compare almeno una volta.

Input L'input di una convolutional neurale network o ConvNet è una immagine, ossia una matrice di valori di ogni singolo pixel occupante una precisa posizione all'interno dell'immagine. Nel caso di immagini RGB, questa sarà descritta da un terna di matrici dell'intensità dei colori primari (rosso, verde, blu), nel caso di immagini in bianco e nero, queste sono descritte da una singola matrice. Le matrici che compongono le immagini, identificano i **canali** (o profondità) della rete. In generale la ConvNet opera su strutture a griglia contraddistinte da relazioni spaziali tra pixel, ereditate da uno strato al successivo tramite valori che descrivono piccole regioni locali dello strato precedente. L'insieme di matrici degli strati nascosti (hidden layer), ottenute dalla convoluzione o da altre operazioni, sono definite feature map o activation map, i parametri addestrabili invece sono tensori denominati filtri o kernel.[12]

4.1.1 L'architettura

Una CNN è composta da una successione di strati che si possono ripetere. Gli strati principali sono:

- convolutional layer;
- activation layer;
- pooling layer;
- dense layer;

[12] Di ciascuno sarà data una breve descrizione in seguito.

4.1.2 Convolutional layer

Per l'analisi delle immagini, il ConvLayer ha dimostrato di avere molto successo nell'ottenere buoni risultati. Successo ottenuto data la sua

capacità di estrarre le piccole caratteristiche che compongono un'immagine. Per estrarre viene applicata un kernel o filtro, di dimensioni [n x n x canale], in ogni possibile posizione dell'immagine, coprendola interamente, e computa il prodotto scalare tra il filtro stesso e la matrice corrispondente del volume di input, avente uguali dimensioni. È possibile visualizzare la convoluzione come una sovrapposizione del kernel sull'immagine in input (o strato nascosto). [1] Il risultato di questa operazione è una nuova matrice (feature map) di dimensioni pari o minori rispetto alla matrice in ingresso. In particolare le dimensioni della feature map dipendono da due fattori, lo stride e il padding. Lo stride indica il numero di pixel di cui la matrice si sposta dopo ogni operazione mentre il padding definisce il comportamento del kernel sui bordi della matrice a cui è applicata.[8]

Questa sua capacità di estrarre le caratteristiche da una matrice in input combinata con la sua multipla presenza nella rete, permette alla ConvNet di distinguere forme sempre più complesse. Questo grazie proprio alla capacità del filtro di modificarsi al fine di apprendere le caratteristiche dei pattern delle immagini. Infatti i filtri dei primi strati individuano forme primitive, quelli successivi imparano a distinguere forme sempre più grandi e complesse, richiedendo così lunghe sequenze di blocchi di strati per studiare un'immagine intera.[12]

4.1.3 Funzione di attivazione Relu

L'operazione di attivazione non-lineare segue l'operazione di convoluzione. Per ogni strato, la funzione di attivazione genera uno strato di eguale dimensione di valori limitati da soglie: in quanto semplice mappatura uno-a-uno dei valori di attivazione, la funzione ReLU non altera l'impronta spaziale dello strato.

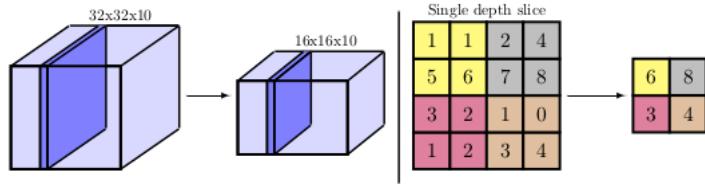


Figure 7: Esempio di pooling con uno stride e una dimensione del filtro pari a due.

4.1.4 Pooling layer

Il pooling è una tecnica che viene utilizzata per estrarre le informazioni più utili da un'area in uno strato convoluzionale e quindi ridurle la quantità di informazioni da analizzare nella fase successiva. L'area di input del livello di raggruppamento è chiamata livello di filtro ed è l'equivalente del livello del campo ricettivo del ConvLayer. Il parametro stride nel pooling layer, oltre a comportarsi allo stesso modo del omonimo del convlayer, è importante per tre motivi: il primo è la riduzione dell'impronta spaziale delle mappe di attivazione, il secondo è un certo grado di invarianza alla traslazione e il terzo è un incremento del campo ricettivo.[1] Esistono diversi tipi di pooling, ma la variante che si è dimostrata avere maggior successo è il max pooling, siccome estrae il massimo valore contenuto in matrici quadrate di ogni mappa di attivazione e produce un altro hidden layer di eguale profondità. Un altro motivo del loro successo è il grado di non-linearietà e invarianza alla traslazione che introducono.[1]. E proprio quest'ultima variante sarà utilizzata nel progetto. Un esempio di come può essere utilizzato il max pooling è mostrato nella Figura 7 , dove viene utilizzata uno stride e una dimensione del filtro di 2x2.

4.1.5 Dense layer

Connette ogni feature in input con la corrispondente feature in output. Presenta la struttura di una rete feed-forward tradizionale e aumenta a dismisura il numero di parametri addestrabili per effetto del numero di

N.	Layer	Dimensioni filtro	Output Shape
0	Input	-	800X600X3
1	Conv2d	3X3	800X600X16
2	ReLU	-	800X600X16
3	Max pooling2d	-	400X300X16
4	Conv2d	3X3	400X300X32
5	ReLU	-	400X300X32
6	Max pooling2d	-	200X150X32
7	Conv2d	3X3	200X150X64
8	ReLU	-	200X150X64
9	Max pooling2d	-	100X75X64
10	Flatten	-	48000
11	Dense	-	512
12	Dense	-	1

Table 1: Struttura della rete sviluppata

connessioni. Ad esempio, se due strati completamente connessi hanno 4096 unità ciascuno, il numero di connessioni (quindi di parametri) sarà superiore a 16 milioni. [1]

4.1.6 Struttura della rete sviluppata

La rete impiegata per il progetto è stata sviluppata in python, impiegando la libreria Tensorflow nella versione 1.14. La sua struttura ha la forma definita nella tabella 1

	Train		Validation	
	train loss	train acc	val loss	val acc
Classi				
Blur 3.5	2,26E-12	1	1,97E-12	1
black	0	1	3,92E-36	1
brightness	2,26E-16	1	1,97E-16	1
50 death pixels	0,6932	0,5	0,6932	0,5
200 death pixels	0,6932	0,5	0,6932	0,5
nodemos	9,84E-20	1	2,06E-26	1
noise	2,42E-13	1	4,18E-17	1
sharpness	0,0015	1	2,93E-27	1
brokenlens	5,93E-16	1	4,30E-16	1
icelens	0,0089	0,9995	0,0017	0,9996
banding	0,0132	0,9995	0,0026	0,9992
greyscale	2,26E-22	1	2,22E-22	1
condensation	1,03E-19	1	1,73E-17	1
dirty lens	0,0157	0,9985	0,028	0,9977
chromaticaberration	2,96E-17	1,0,1		
rain	1,58E-16	1	5,03E-28	1
all	0,0996	0,9358	0,0965	0,9337

Table 2: Tabella dei risultati della fase di training e validation

5 Esecuzione e risultati

5.1 Addestramento del rete convuluzionale

Dopo aver definito la struttura della rete, e avendo suddiviso il dataset in tre parti: training set, validation set e test set, la fase successiva prevede l’addestramento della rete. Il training set viene utilizzato per addestrare la CNN utilizzando la regressione logistica, che addestrerà la rete neurale convoluzionale, che sarà spiegato di seguito. Dopo ogni round di training, la rete è testata su una parte casuale del validation set. Il risultato viene utilizzato per valutare l’accuratezza della rete nel rilevare gli oggetti corretti, al fine di determinare se i pesi vengono regolati nel modo migliore. Il test set viene utilizzato per valutare le prestazioni della CNN dopo che il processo di formazione è terminato. Tuttavia, può essere pericoloso modificare la rete in base ai risultati utilizzando il set di test, a causa del rischio di overfitting.[7].

Per la fase di training, sono state eseguite 5 epoch con batch di dimensione 4. È stata impiegata come metrica, Accuracy mentre come funzione di loss, BinaryCrossentropy I risultati sia della fase del training sia della validation sono mostrati nella tabella 2 Da questi primi risultati si può notare come in generale la rete dia ottimi risultati su tutte le classi in questa fase. Le uniche classi dove questi risultati non sono ottimali sono: 200 death pixel e 50 death pixel. Su queste due si può assumere che l’agente non riesca ad identificare le differenze tra golden run e guasto.

5.2 Testing della rete

Ottenuto 17 reti istruite ciascuna sul proprio dataset di dati, la fase finale del progetto è verificare la loro effettiva efficacia su due set di immagini e verificare l’assenza di overfitting negli agenti. Per ciascuna rete sono stati impiegati due differenti test set:

Table 3: Tabella riassuntiva della prima fase di testing

	singola classe		all	
classi	loss	acc	loss	acc
Blur 3.5	1,79E-20	1	1,92E+03	0,5708
black	1,97E-16	1	7,76E+02	0,5417
brightness	8,41E+02	0.5	5,65E+02	0,442
50 death pixels	0,6932	0,5	0,6932	0,5
200 death pixels	0,6932	0,5	0,6932	0,5
nodemos	3,98E-35	1	7,30E+01	0,5833
noise	4,13E-12	1	4,02E+01	0,5833
sharpness	3,4551	0,9763	2,63E+02	0,6072
brokenlens	2,10E-07	1	3,05E+01	0,5417
icelens	2,6259	0,8182	5817,3185	0,5595
banding	6,7391	0,5469	7197,409	0,3942
greyscale	1,02E+00	0,8938	3,76E+01	0,5
condensation	1,36E-01	0,998	2,36E+02	0,5247
dirty lens	18,5961	0,58	31,0586	0,5076
chromaticaberrration	0,00E+00	1	4719,5721	0,5625
rain	5,15E+00	0,8819	6,97E+01	0,5188
all			668,9222	0,5

- golden run-singolo guasto
- golden run e i restanti guasti-singolo guasto

Quest'ultimo avendo sempre 14400 elementi, risulta essere sbilanciato, avendo nella prima classe un numero superiore della seconda. Per una prima fase di testing le metriche usate sono sempre le stesse della fase di training ovvero Accuracy e BinaryCrossentropy. I risultati ottenuti sono mostrati alla seguente Tabella 3 Si può notare da quest'ultima che per 200 e 50 death pixels, le affermazioni espresse in precedenza sono confermate siccome effettivamente l'agente "tira ad indovinare"

l'appartenenza di un dato ad una determinata classe.

6 Conclusioni e lavori futuri

7 A Manuale utente

References

- [1] Charu C Aggarwal et al. *Neural networks and deep learning*. Springer, 2018.
- [2] Algirdas Avizienis et al. “Basic concepts and taxonomy of dependable and secure computing”. In: *IEEE transactions on dependable and secure computing* 1.1 (2004), pp. 11–33.
- [3] Andrea Bondavalli. *L’analisi quantitativa dei sistemi critici: Fondamenti e Tecniche per la Valutazione-Analitica e Sperimentale-di Infrastrutture Critiche e Sistemi Affidabili*. Società Editrice Esculapio, 2011.
- [4] Plaban Das. “Risk analysis of autonomous vehicle and its safety impact on mixed traffic stream”. In: (2018).
- [5] Logan Engstrom et al. “Exploring the landscape of spatial robustness”. In: *International Conference on Machine Learning*. 2019, pp. 1802–1811.
- [6] Kevin Eykholt et al. “Robust physical-world attacks on deep learning visual classification”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2018, pp. 1625–1634.
- [7] Isabelle Guyon. “A scaling law for the validation-set training-set size ratio”. In: *AT&T Bell Laboratories* 1.11 (1997).
- [8] Niklas Mattsson. *Classification Performance of Convolutional Neural Networks*. 2016.
- [9] David M Nicol, William H Sanders, and Kishor S Trivedi. “Model-based evaluation: from dependability to security”. In: *IEEE Transactions on dependable and secure computing* 1.1 (2004), pp. 48–65.

- [10] Stuart J Russell and Peter Norvig. *Intelligenza artificiale. Un approccio moderno*. Vol. 1. Pearson Italia Spa, 2005.
- [11] Francesco Secci and Andrea Ceccarelli. “On failures of RGB cameras and their effects in autonomous driving applications”. In: *arXiv preprint arXiv:2008.05938* (2020).
- [12] Luca Torresin. “Sviluppo ed applicazione di reti neurali per segmentazione semantica a supporto della navigazione di rover marziani”. In: (2019).
- [13] Wikipedia. *Visione artificiale — Wikipedia, L’enciclopedia libera*. [Online; in data 15-ottobre-2020]. 2020. URL: http://it.wikipedia.org/w/index.php?title=Visione_artificiale&oldid=111327669.